

Reflexión y analistas EDA Spam/Ham

1. Cambios más notorios tras el preprocesamiento

Al comparar el texto original con el texto ya preprocesado, los cambios se notan bastante. Primero, desaparecen muchas palabras comunes como “the”, “to” o “you”, que antes dominaban completamente el análisis. Esto ayuda mucho porque ahora sí se pueden ver palabras que realmente diferencian entre spam y ham.

También se reduce bastante la longitud de los mensajes. Aun así, el spam sigue siendo más largo que el ham, aproximadamente el doble, lo cual parece ser una característica importante.

Otro cambio clave es que los vocabularios se separan mucho mejor. Antes, ambos tipos de mensajes se veían muy similares, pero después del preprocesamiento el spam muestra palabras más “comerciales” como “free”, “win” o “urgent”, mientras que el ham tiene palabras más cotidianas como “go”, “home” o “think”.

Además, la lematización ayuda a agrupar palabras similares (por ejemplo, “calling”, “called” y “calls” pasan a ser “call”), lo que hace que los patrones sean más claros.

Finalmente, las distribuciones de longitud también se ven más ordenadas y separadas, lo que facilita distinguir entre ambos tipos de mensajes.

2. Palabras más frecuentes

a. ¿Hay palabras en común?

Sí, hay bastantes palabras que aparecen tanto en spam como en ham, como “call”, “go”, “get”, “time” o “day”. Estas palabras son muy comunes en inglés, así que por sí solas no ayudan mucho a distinguir entre clases.

b. ¿Qué palabras son exclusivas?

En el caso del spam, aparecen palabras como “free”, “win”, “prize”, “urgent” o “cash”, que claramente buscan llamar la atención o persuadir al usuario.

Por otro lado, en el ham aparecen palabras como “home”, “love”, “sorry”, “dinner” o “meeting”, que reflejan conversaciones normales entre personas.

c. ¿Qué patrones se pueden observar?

Se pueden notar varios patrones interesantes:

- El spam usa mucho lenguaje de recompensa o urgencia, como “free” o “win”.
- También incluye muchas instrucciones directas, como “reply” o “claim”.
- El ham, en cambio, tiene un tono más personal y emocional, con palabras como “love” o “miss”.
- Además, el ham tiene un vocabulario mucho más variado, mientras que el spam repite muchas veces las mismas palabras.
- El spam también usa términos relacionados con tecnología o telefonía, como “txt” o “mobile”.

3. Características útiles para clasificar

A partir del análisis, hay varias características que podrían ayudar a un modelo a distinguir entre spam y ham:

- La longitud del mensaje, ya que el spam suele ser más largo.
- La presencia de ciertas palabras clave como “free”, “win” o “urgent”.
- El uso de mayúsculas o signos de exclamación, que el spam usa para llamar la atención.
- La presencia de números de teléfono o enlaces.
- El uso de TF-IDF para medir qué tan importante es cada palabra.
- La proporción de stopwords, ya que el ham tiende a tener más lenguaje natural.
- Y las palabras de acción como “reply” o “send”, que son comunes en spam.