

Sección de Reflexión — EDA Spam/Ham

Universidad del Valle de Guatemala | Inteligencia Artificial

1. ¿Qué cambios son más notorios entre los indicadores antes y después del preproceso?

Al comparar los análisis exploratorios antes y después del pipeline de preprocesamiento (minúsculas, eliminación de puntuación, tokenización, stopwords y lematización), los cambios más notorios son:

- **Desaparición de stopwords dominantes:**

En el texto original, palabras funcionales como "to", "the", "a", "I", "you" encabezaban el ranking de frecuencias en AMBAS clases con diferencias mínimas entre ellas, enmascarando completamente el vocabulario discriminativo. Tras el preprocesamiento, estas palabras desaparecen y emergen términos con carga semántica real.

- **Reducción significativa de la longitud:**

La cantidad promedio de palabras por mensaje disminuye considerablemente: en HAM de 13.5 a 7.1 palabras, y en SPAM de 23.8 a 14.7 palabras. Pese a esta reducción absoluta, la diferencia relativa se mantiene: el spam sigue siendo aproximadamente el doble de largo que el ham, confirmando que la longitud es una característica robusta.

- **Vocabularios claramente diferenciados:**

Antes del preprocesamiento las nubes de palabras de spam y ham eran casi indistinguibles (dominadas por las mismas stopwords). Después, el vocabulario del spam muestra un perfil marcadamente comercial y agresivo ("free", "win", "prize", "claim", "urgent"), mientras que el del ham refleja comunicación cotidiana y afectiva ("go", "know", "come", "think", "home").

- **Normalización morfológica visible:**

La lematización unifica formas verbales y nominales: "calling", "called", "calls" se consolidan en "call", aumentando su frecuencia y haciendo los patrones más evidentes en ambas clases. Esto no sería posible con el texto crudo.

- **Separación más clara en las densidades de longitud:**

Los gráficos KDE post-preprocesamiento muestran distribuciones más compactas y con mayor separación entre clases, lo que indica que los mensajes procesados son más uniformes y facilitan la discriminación.

2. Respecto a las 20 palabras más frecuentes en ambos grupos

2a. ¿Hay palabras en común entre spam y ham?

Sí. El análisis de vocabulario del texto preprocesado identificó 896 palabras compartidas entre ambas clases. Las más frecuentes son verbos y sustantivos neutros del inglés cotidiano:

call, go, get, know, come, time, day, good, want, think, need, back, one, like, see, still, take, make, right, new

Estas palabras aparecen en ambas clases porque son parte del lenguaje ordinario. Por sí solas no tienen poder discriminativo, aunque su frecuencia relativa (calculada con TF-IDF) podría aportar señal en combinación con otras características.

2b. ¿Qué palabras son exclusivas de cada clase?

Exclusivas de SPAM (959 términos)	Exclusivas de HAM (4 941 términos)
free, win, prize, claim	home, morning, night, miss
urgent, guaranteed, award	tomorrow, week, feel, dear
txt, mobile, nokia, ringtone	sleep, love, sorry, late
cash, voucher, service, tone	dinner, birthday, party, weekend
reply, stop, opt, customer	college, class, office, meeting
selected, congrats, winner	mum, dad, sis, bro, mate

2c. ¿Qué información o patrones se deducen de estas diferencias?

Las diferencias de vocabulario revelan tres patrones lingüísticos fundamentales:

- Lenguaje de recompensa inmediata en spam: términos como "free", "win", "prize", "guaranteed" y "cash" buscan activar la respuesta emocional del receptor y generar acción inmediata (call, reply, stop).
- Lenguaje de acción/CTA (Call To Action) en spam: "reply", "stop", "opt", "send", "claim" son instrucciones directas. El spam casi siempre exige que el destinatario haga algo.
- Lenguaje afectivo y temporal en ham: términos como "miss", "love", "sorry", "dear" junto con referencias temporales ("morning", "tomorrow", "week") son típicos de conversaciones genuinas entre personas.
- Mayor diversidad léxica en ham: con 4 941 palabras exclusivas frente a 959 del spam, el ham usa un vocabulario mucho más variado y natural. El spam, en cambio, repite un conjunto reducido de términos de alto impacto.
- Términos técnicos de telecomunicaciones en spam: "txt", "mobile", "nokia", "ringtone", "tone" indican que el spam SMS explota la plataforma móvil para ofrecer servicios de dudosa procedencia.

3. ¿Qué características del texto podrían ser útiles para distinguir spam de ham?

A partir del análisis exploratorio, se identifican las siguientes características con mayor potencial discriminativo para un clasificador:

Característica	Justificación
Longitud (chars y palabras)	El spam es ~2x más largo que el ham tanto en chars como en palabras.
Palabras clave de spam	"free", "win", "prize", "claim", "urgent" aparecen casi exclusivamente en spam.
Mayúsculas y exclamaciones	El spam usa recursos tipográficos para enfatizar urgencia (FREE!!, WIN!!, CALL NOW!!).
Números de teléfono y URLs	Instrucciones de acción muy frecuentes en spam; prácticamente ausentes en ham.
TF-IDF sobre vocab. preprocesado	Captura la importancia relativa de cada término y penaliza los compartidos.

Laboratorio 6 — Clasificación Spam/Ham | Sección de Reflexión

Proporción stopwords / total tokens	El ham retiene más stopwords; el spam es más denso en contenido informativo.
Términos de CTA (reply, stop, call, opt)	La presencia de instrucciones directas es un indicador fuerte de spam.
Diversidad léxica (type-token ratio)	El spam repite términos clave; el ham tiene mayor variedad léxica.

Conclusión: la combinación de características léxicas (vocabulario exclusivo de spam), estructurales (longitud) y estilísticas (mayúsculas, CTA, signos de exclamación) ofrece un conjunto de features robusto. El siguiente paso natural es vectorizar el texto preprocesado con TF-IDF y entrenar un clasificador como Naive Bayes multinomial o Regresión Logística, complementado con las características numéricas identificadas.